

Impacto de mudanças climáticas no contexto atuarial

João Victor Barboza Machado das Neves
Patrick Oliveira da Silva Filho

Orientação: Mariane Alves, Thais Fonseca e Viviana Lobo


15ª Semana de Integração Acadêmica — SIAC 2026

CONTEXTO

Desastres climáticos atingiram em 2021–2025 o maior número das últimas duas décadas, elevando a incerteza sobre o risco segurado

Número de desastres climáticos no mundo

de eventos por período de 5 anos



1.959

desastres climáticos em 2021–2025, o maior valor da série

Implicação para seguros

Com eventos mais frequentes, o histórico médio passa a refletir menos o risco atual, e a frequência de sinistros fica mais incerta.

Fonte: EM-DAT (CRED/UCLouvain). Exclui desastres geofísicos.

CONTEXTO

Eventos climáticos extremos podem tornar a frequência de sinistros mais volátil e menos previsível pela média histórica




Sinistros mensais em uma região

Esquema ilustrativo



O PROBLEMA

Quando o mesmo evento atinge áreas próximas, os sinistros deixam de ser independentes entre regiões



Área atingida por um mesmo evento climático

1

Um evento, várias células

A mesma chuva intensa atinge células vizinhas no mesmo mês

2

Sinistros sobem juntos


Células próximas tendem a registrar picos ao mesmo tempo

3

Independência deixa de valer


Tratar cada célula isoladamente ignora essa co-ocorrência

Modelos convencionais captam exposição, risco e clima, mas não representam explicitamente a dependência espacial

	Negative Binomial (NB)	Random Forest (RF)
Estrutura	$Y_{g,t} \sim \text{NB}(\mu_{g,t}, \varphi)$ $\log \mu_{g,t} = \log E_{g,t} + \beta_0 + \beta' X_{g,t}$ $Y_{g,t}$ sinistros na célula g, mês t $E_{g,t}$ exposição (domicílios segurados) $X_{g,t}$ covariáveis de clima e carteira	 Média de muitas árvores de decisão, cada uma treinada numa amostra dos dados
Captura	Contagens com sobredispersão Exposição como escala do risco (offset)	Relações não lineares e interações Sem forma funcional imposta
Fica faltando	Dadas as covariáveis, cada célula é tratada como independente das vizinhas	Nenhuma estrutura espacial explícita; exposição entra como variável comum

A PROPOSTA

O modelo proposto (SP-NB) adiciona ao risco próprio de cada célula a informação de ocorrência anormal de sinistros nos vizinhos



Sem vizinhos em choque no mês anterior, o SP-NB reduz-se à própria NB.

Fonte: Gudmundarson, Tzougas e Christopoulos (2026). Insurance ratemaking for climate-related claim counts using mixed Poisson spatio-temporal and temporal Besag regression models. European Actuarial Journal.

A PROPOSTA

A intensidade esperada combina exposição, características do risco e propagação espaço-temporal

$$Y_{g,t} \sim \text{NB}(\lambda_{g,t}, \varphi)$$

$$\lambda_{g,t} = E_{g,t} \cdot [\exp(\beta' X_{g,t}) + \psi_g \cdot \sum_j A_{gj} \bar{Y}_{j,t-1}]$$

$E_{g,t}$

Exposição

Escala a taxa pelo nº de domicílios segurados

$\exp(\beta' X_{g,t})$

Risco próprio

Efeito do clima e da composição da carteira

ψ_g

Sensibilidade da célula

Intensidade da propagação para g; estimada por célula, não negativa


$\sum_j A_{gj} \bar{Y}_{j,t-1}$

Vizinhos em choque

Nº de vizinhos Queen em choque no mês anterior

A PROPOSTA


A matriz Queen define quais células compartilham informação espacial



Célula interna: 8 vizinhos (lados + diagonais)


$A_{gj} = 1$ se g e j compartilham um lado ou um vértice

$A_{gj} = 0$ caso contrário



5

vizinhos na borda



3

vizinhos no canto

No caso estudado : 9 células internas, 12 de borda e 4 de canto


A PROPOSTA

Uma célula entra em estado de choque quando os sinistros superam o nível esperado para sua exposição

Sinistros mensais de uma célula

— — — Nível esperado para a exposição

Esquema ilustrativo



1

Observado

Sinistros da célula no mês, $Y_{g,t}$

2

Referência

Nível esperado dada a exposição $E_{g,t}$

3


Choque

$\tilde{Y}_{g,t} = 1$ se observado > referência; 0 caso contrário

[Confirmar no código: na referência, o limiar é o quantil 80% de uma Poisson com média = frequência global × exposição]

ESTUDO DE CASO

Construímos um painel mensal de 25 células no entorno de Taquari (RS) para testar a abordagem



[Inserir mapa de localização e tamanho da célula]

25

células em malha 5×5

300

meses: jan/2001 a dez/2025

7.500

observações célula-mês

12.855

sinistros no período

15.000

domicílios segurados (exposição média mensal)

célula × mês

unidade de observação

ESTUDO DE CASO

Cada célula-mês combina exposição, clima, composição da carteira e número de sinistros

Uma linha da base = célula g × mês t

Identificação

Células (25)

Mês (300)

Sinistros e exposição

Y: nº de sinistros

E: domicílios seguros

Clima

Precipitação mensal

Precipitação máxima

Dias extremos

Precipitação em t-1

Carteira

% imóveis com 2 pisos

% imóveis com 3+ pisos

% qualidade média

% qualidade baixa

% idade 11–20 anos

% idade 21–30 anos

% idade 30+ anos

Espacial

Vizinhos em choque, t-1

apenas no SP-NB

Covariáveis padronizadas (z-score) antes do ajuste.

[Confirmar fonte da precipitação: CHIRPS]

ESTUDO DE CASO

NB, Random Forest e SP-NB Queen são comparados sobre a mesma base e o mesmo período de teste

Divisão temporal

Treino 2001–2020 · 6.000 obs. · 9.954 sinistros

Teste 2021–2025
1.500 obs. · 2.901 sinistros

Negative Binomial

Benchmark estatístico de contagem

Random Forest

Benchmark de machine learning

SP-NB Queen

NB + choque dos vizinhos em $t-1$

Mesmas covariáveis de clima e carteira, mesma janela de treino e de teste

Por observação célula-mês

Erro mês a mês

MAE

RMSE

R^2

Correlação

Balance

Por célula, acumulado no teste

Distribuição espacial do total

Acurácia % por célula

MAE e RMSE por célula

Correlação por célula

$Acurácia_g = 100 \cdot (1 - |Y_g - \hat{Y}_g| / Y_g)$, truncada em 0

RESULTADOS

O SP-NB Queen teve o melhor desempenho em todos os critérios globais, com vantagem modesta sobre a NB

Métrica	Negative Binomial	Random Forest	SP-NB Queen
RMSE célula-mês ↓	2,10	3,04	2,09
MAE célula-mês ↓	1,18	1,27	1,17
R ² ↑	0,753	0,482	0,755
Acurácia média por célula ↑	87,1%	87,6%	87,7%
RMSE agregado por célula ↓	18,6	23,5	17,2
Balance (ideal = 1,00)	1,05	0,91	1,04

Erro do SP-NB vs. NB

-0,4% RMSE célula-mês

-1,2% MAE célula-mês

-7,3% RMSE por célula

Random Forest

RMSE 45% maior que a NB

Subestima o total: **2.650** previstos vs. 2.901 observados

↓ menor é melhor ↑ maior é melhor · Teste 2021–2025: 2.901 sinistros observados

$Acurácia_g = 100 \cdot (1 - |Y_g - \hat{Y}_g| / Y_g)$, truncada em 0

RESULTADOS

No espaço, o SP-NB Queen eleva para 15 as células com acurácia acima de 90%, contra 12 nos outros dois modelos

Negative Binomial

93,9	94,0	70,5	98,2	93,5
89,9	81,1	90,1	100,0	94,8
93,6	91,5	64,2	88,5	70,4
94,1	87,6	94,1	88,0	77,5
75,8	70,3	99,0	86,0	89,9

12 células > 90%

Média 87,1% · Mediana 89,9%

Random Forest

97,6	96,6	88,0	98,2	86,0
90,7	70,6	90,0	99,3	96,7
78,2	91,8	66,6	86,0	82,3
96,3	71,0	80,1	95,5	96,9
98,5	93,5	76,9	83,3	79,5

12 células > 90%

Média 87,6% · Mediana 90,0%

SP-NB Queen

93,4	95,2	72,8	97,9	91,5
95,4	81,5	91,7	96,3	94,4
89,0	88,7	58,6	90,2	72,4
96,0	89,5	94,3	92,2	79,2
79,2	73,6	98,9	90,4	91,7

15 células > 90%

Média 87,7% · Mediana 91,5%

Acurácia por célula (%), mesma escala:



RF acerta melhor algumas células isoladas, mas erra mais no agregado

CONCLUSÃO

Incorporar a dependência espaço-temporal melhorou a previsão neste experimento, ainda que com ganhos modestos

1

Modelos tradicionais seguem úteis

A NB é um benchmark forte: RMSE célula-mês só 0,4% acima do SP-NB

2

RF traz flexibilidade, mas não bastou

Capta não linearidades, porém teve R^2 de 0,48 e subestimou o total

3

SP-NB Queen liderou todos os critérios

Ao incorporar os vizinhos, teve o menor erro e 15 células acima de 90%

Limitação

A base contém componente simulado (o ψ verdadeiro é conhecido) e cobre uma única área de 25 células.

Os resultados precisam ser validados em uma base real de sinistros.

Próximo passo: validar em dados reais e testar outras definições de choque e vizinhança.

Referências

BOUDREAULT, M.; CLACHER, I.; LI, J. S.-H.; PIGOTT, C.; ZHOU, R. A changing climate for actuarial science. **Annals of Actuarial Science**, Cambridge, v. 17, p. 415–419, 2023. DOI: 10.1017/S1748499523000222.

CRED/UCLOUVAIN. **EM-DAT: The International Disaster Database**. Bruxelas. Disponível em: www.emdat.be.

GUDMUNDARSON, R. L.; TZOUGAS, G.; CHRISTOPOULOS, D. Insurance ratemaking for climate-related claim counts using mixed Poisson spatio-temporal and temporal Besag regression models. **European Actuarial Journal**, 2026. DOI: 10.1007/s13385-025-00443-6.

JESSUP, S.; MAILHOT, M.; PIGEON, M. Impact of combination methods on extreme precipitation projections. **Annals of Actuarial Science**, Cambridge, v. 17, p. 459–478, 2023. DOI: 10.1017/S174849952300009X.

ZOU, J.; ODENING, M.; OKHRIN, O. Plant growth stages and weather index insurance design. **Annals of Actuarial Science**, Cambridge, v. 17, p. 438–458, 2023. DOI: 10.1017/S1748499523000167.